

Universidad Nacional Autónoma de México



Facultad de Ingeniería

Análisis y Procesamiento Inteligente de Textos

Grupo: 01

Proyecto Final

Extracción espacial de entidades en informes radiológicos mediante reglas y modelos secuenciales

Fecha de entrega

15 de Noviembre de 2026

Profesor

Mtro. Octavio Augusto Sanchez Velazquez

Alumno

Montiel Juárez Oscar Iván

320018277

¿Dónde está el hallazgo? Extracción espacial de entidades en informes radiológicos mediante reglas y modelos secuenciales

Proyecto de procesamiento inteligente de texto

Resumen

Los informes radiológicos describen hallazgos y ubicaciones anatómicas en lenguaje libre. Este trabajo estudia una tarea lingüística acotada: dado un indicador espacial ya identificado en un informe de radiografía de tórax, extraer los fragmentos que expresan el hallazgo (*Trajector*) y su ubicación (*Landmark*). Se auditó una copia concreta del corpus inglés Rad-SpRL y se fijó una partición de 1 400 informes de entrenamiento, 300 de validación y 300 de prueba, con textos exactamente duplicados agrupados. Se compararon una línea base léxica de proximidad, dos campos aleatorios condicionales (CRF) de etiquetado BIO y un híbrido de rescate previamente definido. La métrica fue F1 micro de fragmentos exactos condicionados al indicador verdadero. En prueba, reglas, CRF e híbrido obtuvieron respectivamente 0.668, 0.883 y 0.871. El CRF mejoró a las reglas en 0.215 puntos de F1 (intervalo percentil bootstrap apareado por informe: [0.175, 0.257]); el híbrido perdió 0.012 frente al CRF. La hipótesis de que la combinación superaría a ambos componentes no recibió respaldo. Los resultados no incluyen detección de indicadores ni miden corrección diagnóstica o seguridad clínica.

Palabras clave: procesamiento de lenguaje clínico; informes radiológicos; extracción de información; relaciones espaciales; CRF; evaluación reproducible.

1. Introducción

Un informe radiológico no es una lista independiente de palabras. La frase construida *"opacity in the left lung"* contiene una observación, una ubicación y una expresión que las vincula. Extraer solamente *opacity* perdería el lugar; extraer sólo *left lung* perdería qué se observó allí. Esta estructura es importante para la recuperación y organización de información clínica, aunque extraerla correctamente del texto no equivale a interpretar una radiografía ni a emitir un diagnóstico [1, 2].

El etiquetado de roles espaciales (*Spatial Role Labeling*, SpRL) representa explícitamente objetos, lugares y expresiones relacionales [3, 4, 5]. Su adaptación radiológica, Rad-SpRL, añade el vocabulario y las convenciones de los informes médicos [6, 9]. En este estudio se considera únicamente la identificación de dos roles asociados a un indicador espacial *proporcionado*; localizar dicho indicador desde un informe sin marcar sería otra tarea.

La pregunta de investigación es: *¿mejora una combinación sencilla de reglas y un modelo secuencial la extracción exacta de hallazgos y lugares respecto de cada componente?* Se contrastaron tres sistemas bajo la misma partición y métrica. Se anticipó que un modelo secuencial tendría mayor exhaustividad global que un léxico fijo y se planteó como hipótesis principal que un híbrido podría elevar la F1. El resultado negativo de esta última hipótesis se conserva y analiza. El aporte no es proponer un nuevo esquema clínico ni superar al trabajo original, sino ofrecer una comparación controlada, reproducible y explícita sobre lo que la métrica *sí* y *no* mide.

2. Estado de la cuestión

2.1. Del texto libre a las relaciones espaciales

Open-i reunió informes e imágenes radiológicas desidentificados para su consulta e investigación [2]. Rad-SpRL seleccionó 2 000 informes de radiografía de tórax de esa procedencia y anotó expresiones espaciales y roles asociados [6, 7]. La copia del XML utilizada aquí procede del repositorio de los autores [8]; su contenido exacto y diferencias frente a los conteos publicados se describen en la sección experimental. La página de Mendeley identifica su versión 1 como CC BY 4.0, pero no se ha comprobado que su archivo sea idéntico byte a byte al de GitHub; por ello este reporte no redistribuye informes ni anotaciones completas [7].

El artículo original de Rad-SpRL evaluó un BiLSTM–CRF, BERT y XLNet para indicadores y roles; comunicó una F1 global máxima de 92.9 con indicadores verdaderos bajo validación cruzada repetida y cuatro roles [9]. Ese número **no** es numéricamente comparable al de este trabajo: aquí hay una sola partición, se evalúan sólo dos roles y se usa nuestra definición explícita de mención exacta. Estudios posteriores exploraron representaciones sintácticas para los roles [10], un híbrido para *detectar indicadores* [11], un esquema espacial más fino en Rad-

SpatialNet [12] y extracción mediante preguntas sucesivas [13]. El híbrido de este artículo combina *roles* bajo un indicador ya conocido; tampoco replica aquel híbrido para indicadores.

2.2. Esquemas cercanos y modelos alternativos

CheXpert utiliza informes para etiquetar observaciones e incertidumbre, y NegBio se centra en el alcance de negación e incertidumbre [14, 15]. Ambos motivan aplicaciones de procesamiento de texto radiológico, pero sus etiquetas no equivalen a los roles espaciales de Rad-SpRL. MIMIC-CXR es otra fuente amplia de informes vinculados con imágenes [16]; no se empleó en nuestros experimentos. RadGraph anota entidades y relaciones clínicas más generales, mientras que RadGraph-XL extiende su escala y diversidad de modalidades [17, 18]. Comparar sus F1 con la nuestra sin armonizar corpus y esquemas sería metodológicamente incorrecto.

Los encoders preentrenados BERT, BioBERT, ClinicalBERT, PubMedBERT y RadBERT ilustran distintos grados de adaptación del lenguaje general al biomédico, clínico o radiológico [21, 22, 23, 24, 25]. Son candidatos razonables para otro experimento, no resultados de éste: aquí se eligió un CRF ligero y entrenable en CPU para establecer una comparación secuencial reproducible. La evidencia de otros conjuntos no autoriza afirmar que un modelo biomédico mejoraría necesariamente esta partición.

3. Marco teórico

3.1. Unidad de predicción y anotaciones

Cada relación de Rad-SpRL parte de un *Spatial Indicator*, generalmente una preposición. El *Trajector* es la entidad cuya posición se describe —habitualmente un hallazgo, aunque el esquema también admite entidades anatómicas— y el *Landmark* es el lugar de referencia. *Diagnosis* y *Hedge* son roles adicionales del corpus, pero no son objetivos de este experimento [6, 9]. En la oración inventada anterior, *in* es el indicador, *opacity* el *Trajector* y *left lung* el *Landmark*. El ejemplo no procede del corpus.

La unidad evaluada es una mención

$$m = (d,\, s_I,\, r,\, s_R), \qquad r \in \{\mathit{Trajector}, \mathit{Landmark}\}, \tag{1}$$

donde d es el informe, s_I los segmentos del indicador y s_R los segmentos de tokens del rol. Cada intervalo usa índices de base cero y extremo derecho exclusivo. Un rol puede contener varios segmentos discontinuos; no se unen rellenando huecos. Una relación también puede tener varios roles del mismo tipo o carecer de alguno. No construimos pares hallazgo–lugar por producto cartesiano porque el XML agrupa roles bajo el indicador, pero no especifica necesariamente esos pares individuales.

3.2. Etiquetado secuencial y CRF

La salida continua se puede aproximar con etiquetas BIO: B inicia un fragmento, I lo continúa y O representa el exterior. Esta codificación es habitual en extracción de entidades, aunque su elección influye en los errores de frontera [20]. Para cada rol entrenamos por separado un campo aleatorio condicional lineal (CRF), que puntúa una secuencia de etiquetas $\mathbf{y}$ dada una secuencia de características $\mathbf{x}$ y aprende dependencias entre etiquetas vecinas [19]:

$$P(\mathbf{y} \mid \mathbf{x}) = \frac{1}{Z(\mathbf{x})} \exp\left(\sum_{t=1}^{T} \sum_{k} \lambda_k f_k(y_{t-1}, y_t, \mathbf{x}, t)\right). \tag{2}$$

Aquí $\mathbf{x}$ incluye rasgos léxicos, ortográficos, vecinos inmediatos y posición respecto al indicador. Al existir dos CRF, un token puede ser candidato a ambos roles; dentro de cada rol, BIO admite varias menciones *continuas*. No puede representar como una sola mención dos fragmentos discontinuos ni dos menciones del mismo rol que se solapen.

3.3. Métrica e incertidumbre estadística

Una predicción cuenta como verdadero positivo sólo si coinciden exactamente informe, indicador, rol y todos los intervalos de tokens. Con conteos agregados, $P = TP/(TP + FP)$, $R = TP/(TP + FN)$ y

$$F_1 = \frac{2PR}{P + R} = \frac{2TP}{2TP + FP + FN}. \tag{3}$$

Se informa cada rol y la F1 micro conjunta. Un límite de frase incorrecto produce a la vez un falso positivo y un falso negativo. Para la diferencia entre sistemas se usó bootstrap *apareado por informe*, preservando dentro de cada muestra todas sus menciones [26]. Los intervalos percentiles describen variabilidad en este conjunto; no demuestran transferencia entre hospitales.

4. Estructura experimental

4.1. Fuente, auditoría y partición

Se analizó la copia `Rad-SpRL.xml` del repositorio de los autores, revisión `20ad32e5`, con SHA-256 `d1a80e6765a6c885720fb030c51616e1b6b3b0b8540f7fcdcf9caa6cbedc173a`. El XML local contiene 2 000 informes, 2 028 relaciones/indicadores, 2 254 menciones *Trajector*, 2 084 *Landmark*, 448 *Diagnosis* y 388 *Hedge*; 938 informes no tienen relación espacial anotada. Los conteos publicados difieren en varios campos (por ejemplo, 1 962 indicadores) [6, 7]. Se desconoce si la causa es una diferencia de versión o de criterio. Por ello los experimentos se atribuyen al XML identificado por su suma de verificación, sin mezclar sus conteos con los del artículo.

Tabla 1: Partición local fijada antes del entrenamiento. Los informes sin relación no aportan indicadores a la métrica principal.

Conjunto	Informes	Con relación	Sin relación	Indicadores
Entrenamiento	1 400	743	657	1 439
Validación	300	159	141	308
Prueba	300	160	140	281
Total	2 000	1 062	938	2 028

La semilla fue 42 y la proporción aproximada 70/15/15. Se estratificó por presencia de alguna relación y se mantuvieron juntos los informes de texto *exactamente* idéntico. Esta precaución reduce una fuga evidente, pero el XML inspeccionado no ofrece identificador de paciente: no se puede certificar independencia por persona ni descartar duplicados casi idénticos. Se verificaron posiciones de caracteres y tokens, roles ausentes y 126 menciones discontinuas; no se eliminaron los casos difíciles.

4.2. Tres sistemas comparables

Reglas léxicas. Con sólo entrenamiento se aprendió un vocabulario de 635 expresiones *Trajector* y 401 *Landmark*, de hasta seis tokens continuos, y la dirección más frecuente de cada rol respecto a cada indicador. La búsqueda se restringió a su oración y a 12 tokens por lado. La selección prioriza lado, proximidad, longitud y frecuencia. Se emite como máximo una mención por rol, de modo que las enumeraciones y las expresiones no vistas son dificultades esperadas.

CRF. Se entrenó un modelo BIO independiente por rol con las 1 439 instancias indicador–oración de entrenamiento. Cada token se representó por forma en minúsculas, patrón ortográfico, prefijos y sufijos de dos y tres caracteres, presencia de dígitos y mayúsculas, palabras y formas a distancia ± 2, texto del indicador, lado y distancia acotada a 12. Se utilizó L-BFGS, penalizaciones $c_1 = c_2 = 0.1$, máximo 100 iteraciones y `python-crfsuite` 0.9.12 [27]. No se realizó una búsqueda de hiperparámetros. Para obtener BIO se separaron 27 menciones discontinuas de *Trajector* y 57 de *Landmark*; 16 y 59 segmentos superpuestos del mismo rol, respectivamente, no podían etiquetarse simultáneamente y se conservó primero el tramo más largo. Son límites del modelo, no una limpieza del conjunto de evaluación.

Híbrido predefinido. Para cada indicador y rol se conservan todas las menciones del CRF si existe al menos una. Sólo cuando el CRF no produce ninguna, se copia la propuesta de reglas. No hay umbral ajustado en validación ni unión indiscriminada de ambas salidas. La regla se registró antes de medir el híbrido; aunque éste perdió ligeramente en validación, se conservó intacta para la prueba.

4.3. Protocolo y reproducibilidad

Los tres métodos reciben los *mismos indicadores verdaderos*. Las predicciones nunca consultan los roles del informe a inferir. La elección de probar el CRF estuvo motivada por errores observados en validación; por eso esas cifras son exploratorias. Antes de generar el archivo de prueba se congelaron código, pesos, partición, métrica y regla híbrida mediante sumas SHA-256. La prueba se abrió una vez para la comparación final; después no se cambiaron algoritmos. Se realizaron 2 000 remuestreos bootstrap por informe con semilla 42 para cada diferencia apareada. Los scripts, configuración y 20 pruebas automatizadas están en el

proyecto `RadioNexo`; los datos y pesos no se incluyen en este documento.

5. Resultados

Tabla 2: Resultados de fragmentos exactos condicionados al indicador verdadero. P: precisión; R: exhaustividad.

Conjunto	Método	P micro	R micro	F1 micro	TP/FP/FN
Validación	Reglas	0.700	0.620	0.658	420/180/257
	CRF	0.878	0.838	**0.857**	567/79/110
	Híbrido	0.851	0.855	0.853	579/101/98
Prueba	Reglas	0.699	0.640	0.668	378/163/213
	CRF	**0.885**	0.882	**0.883**	521/68/70
	Híbrido	0.859	**0.883**	0.871	522/86/69

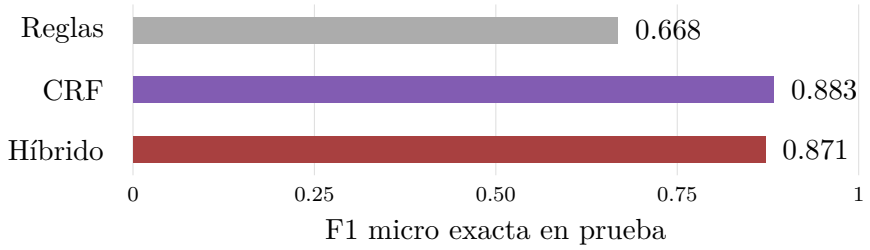


Figura 1: Comparación principal en los mismos 300 informes de prueba. Todos los sistemas reciben indicadores espaciales verdaderos; la barra no representa exactitud diagnóstica.

Tabla 3: F1 exacta por rol en prueba. Las 591 menciones de referencia se dividen en 306 *Trajector* y 285 *Landmark*.

Método	Trajector	Landmark
Reglas	0.640	0.697
CRF	**0.888**	**0.878**
Híbrido	0.868	0.873

El CRF supera a las reglas en precisión y exhaustividad tanto en validación como en prueba (tabla 2 y figura 1). En prueba, el híbrido añadió 19 menciones allí donde el CRF no emitía ese rol: una coincidió exactamente con la referencia y 18 fueron falsos positivos. Su ligero

Tabla 4: Diferencias de F1 micro en prueba e intervalos percentiles del bootstrap apareado por informe (2 000 muestras).

Contraste (segundo menos primero)	Diferencia	Intervalo 95 %
CRF − reglas	+0.215	[+0.175, +0.257]
Híbrido − CRF	−0.0123	[−0.0191, −0.0065]

aumento de exhaustividad no compensó la pérdida de precisión. Las diferencias de la tabla 4 se calcularon sin tratar cada mención como una observación independiente.

Como desglose *posterior* a la prueba, se comparó la F1 de los sistemas por informe sólo en los 158 que contienen alguna mención principal anotada. Frente a reglas, el CRF obtuvo mayor F1 en 91, menor en 6 y empató en 61; frente al híbrido, ganó en 13, perdió en 1 y empató en 144. Los empates no implican predicciones idénticas. Estos conteos complementan la F1 micro, pero no cambian la unidad ni la prueba estadística principal.

6. Análisis

6.1. Interpretación de las hipótesis

La hipótesis de mayor exhaustividad *global* del modelo secuencial sí recibió apoyo: en prueba, $R = 0.882$ para CRF y $R = 0.640$ para reglas. No obstante, el planteamiento inicial sugería además ventaja en expresiones *poco frecuentes*; no se realizó una estratificación por frecuencia léxica, de modo que ese aspecto específico sigue sin probarse. La hipótesis principal de superioridad del híbrido no recibió apoyo. El resultado negativo concuerda en validación y prueba, y evita la conclusión automática de que combinar métodos siempre mejora al mejor componente.

6.2. Dónde se equivoca el CRF

El análisis posterior a la prueba fue descriptivo, sin reentrenamiento. En 233 indicadores con exactamente un hallazgo y un lugar continuos, el CRF alcanzó F1 de 0.940. En 35 indicadores con varias menciones de algún rol bajó a 0.760; en 17 con algún rol discontinuo, a 0.465. Los

subgrupos pueden solaparse y son pequeños. En diez indicadores sin ninguno de los dos roles principales anotados, el CRF produjo 16 menciones falsas. Tales casos explican por qué el rescate por léxico tampoco fue fiable: la ausencia de predicción del CRF no significa que exista un rol recuperable. Una extensión parcial de una frase falla la coincidencia exacta aunque comparta palabras con el patrón de referencia; el análisis separó errores de límite y de ausencia de solapamiento.

La figura 2 clasifica las 591 menciones de referencia por longitud y muestra la *exhaustividad* exacta, no F1. El CRF recuperó 169 de 183 menciones de un token, 204 de 220 de dos, 113 de 125 de tres y 35 de 42 menciones continuas de cuatro o más tokens. Ninguno de los tres métodos reconstruyó exactamente las 21 menciones discontinuas de prueba, un límite esperado de la representación BIO y de la línea base. Los grupos de longitud no son pruebas independientes de superioridad.

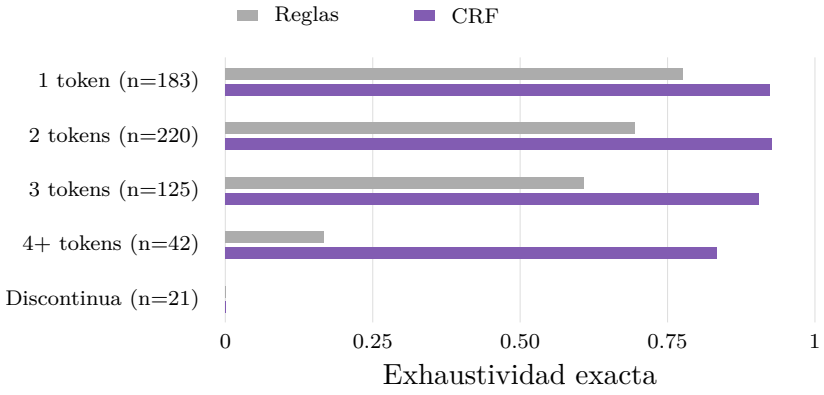


Figura 2: Exhaustividad por longitud de la mención verdadera en prueba. Los tamaños n son menciones, no informes. La categoría discontinua requiere más de un segmento por mención.

El indicador *of* apareció 130 veces y obtuvo F1 de 0.914 con CRF; *in* apareció 71 veces y obtuvo 0.868. Para *with*, sólo 11 indicadores, la F1 fue 0.591. Este último valor señala un caso que merece revisión lingüística, no una conclusión general sobre esa palabra.

6.3. Alcance de la evidencia

Ni 0.883 de F1 ni los intervalos de la tabla 4 representan seguridad clínica. Se midió concordancia con anotaciones de un corpus, no la verdad médica del informe. Se conoce el indicador

de antemano; no hay evaluación de la cadena completa desde texto sin marcas. Tampoco se evaluaron *Diagnosis*, *Hedge*, negación general, imágenes o informes en español. El corpus procede de una sola fuente de radiografías de tórax y carece, en la versión auditada, de identificadores para garantizar separación por paciente. Su cobertura de relaciones espaciales no es una anotación exhaustiva de todos los hallazgos clínicos [6].

La diferencia con los conteos del artículo publicado y la equivalencia aún no verificada entre las copias GitHub y Mendeley son limitaciones de procedencia que deben resolverse antes de redistribuir datos. La prueba de 300 informes es una sola partición. Los resultados de validación y prueba no forman una serie temporal: sus distribuciones y números de indicadores son distintos. La selección del CRF estuvo informada por validación, mientras que el híbrido fue fijado antes de su primera medición. Ningún modelo nuevo debe ajustarse después con esta prueba ya observada.

7. Conclusión

En la extracción de dos roles espaciales condicionada a indicadores verdaderos de Rad-SpRL, un CRF con rasgos lingüísticos locales obtuvo la mejor F1 exacta en la prueba reservada (0.883), por encima de una referencia léxica (0.668). El híbrido de rescate previamente definido no mejoró al CRF (0.871): casi todas sus adiciones fueron falsos positivos. El estudio muestra tanto la utilidad del aprendizaje secuencial para delimitar menciones como el valor de conservar una hipótesis no respaldada y declarar con precisión el alcance de la evaluación. Su salida es una comparación de procesamiento de texto, no una herramienta diagnóstica.

8. Trabajo futuro

Una primera extensión es detectar los indicadores espaciales desde texto sin marcar y medir por separado ese componente y la cadena completa; el antecedente híbrido para indicadores ofrece un punto de partida [11]. Otra es sustituir BIO por un modelo de candidatos de *spans* o una representación que conserve menciones discontinuas y solapadas. Modelos contextuales generales, biomédicos y radiológicos podrían compararse bajo una nueva partición o validación cruzada sin reutilizar la prueba actual para seleccionar hiperparámetros [21, 24, 25].




También queda medir transferencia a otros centros y modalidades, armonizar etiquetas con recursos más amplios como RadGraph-XL [18], y abordar *Hedge* o negación con anotaciones diseñadas para ello [15, 14]. Antes de plantear uso clínico harían falta validación externa, revisión de errores por especialistas y análisis de consecuencias de los fallos.

Bibliografía

[1] Pons, E., Braun, L. M. M., Hunink, M. G. M. y Kors, J. A. (2016). Natural language processing in radiology: A systematic review. *Radiology*, 279(2), 329–343. https://doi.org/10.1148/radiol.16142770.

[2] Demner-Fushman, D. y cols. (2016). Preparing a collection of radiology examinations for distribution and retrieval. *Journal of the American Medical Informatics Association*, 23(2), 304–310. https://doi.org/10.1093/jamia/ocv080.

[3] Kordjamshidi, P., Van Otterlo, M. y Moens, M.-F. (2010). Spatial role labeling: Task definition and annotation scheme. *LREC*. https://aclanthology.org/L10-1584/.

[4] Kordjamshidi, P., Bethard, S. y Moens, M.-F. (2012). SemEval-2012 Task 3: Spatial role labeling. **SEM*, 365–373. https://aclanthology.org/S12-1048/.

[5] Kolomiyets, O., Kordjamshidi, P., Moens, M.-F. y Bethard, S. (2013). SemEval-2013 Task 3: Spatial role labeling. *SemEval*, 255–262. https://aclanthology.org/S13-2044/.

[6] Datta, S. y Roberts, K. (2020). A dataset of chest X-ray reports annotated with Spatial Role Labeling annotations. *Data in Brief*, 32, 106056. https://doi.org/10.1016/j.dib.2020.106056.

[7] Datta, S. y Roberts, K. (2020). *A dataset of chest X-ray reports annotated with Spatial Role Labeling annotations*, Mendeley Data, versión 1. https://doi.org/10.17632/yhb26hfz8n.1.

[8] Roberts Lab. (s. f.). *datasets/rad-sprl*, repositorio de los autores; revisión `20ad32e5` consultada en 2026. https://github.com/krobertslab/datasets/tree/master/rad-sprl.

[9] Datta, S., Si, Y., Rodriguez, L., Shooshan, S. E., Demner-Fushman, D. y Roberts, K. (2020). Understanding spatial language in radiology: Representation framework, annotation, and spatial relation extraction from chest X-ray reports using deep learning. *Journal of Biomedical Informatics*, 108, 103473. https://doi.org/10.1016/j.jbi.2020.103473.

[10] Datta, S. y Roberts, K. (2020). Spatial relation extraction from radiology reports using syntax-aware word representations. *AMIA Joint Summits on Translational Science Proceedings*, 116–125. https://pubmed.ncbi.nlm.nih.gov/32477630/.

[11] Datta, S. y Roberts, K. (2020). A hybrid deep learning approach for spatial trigger extraction from radiology reports. *Proceedings of the Third International Workshop on Spatial Language Understanding*, 50–55. https://doi.org/10.18653/v1/2020.splu-1.6.

[12] Datta, S. y cols. (2020). Rad-SpatialNet: A frame-based resource for fine-grained spatial relations in radiology reports. *LREC*, 2251–2260. https://aclanthology.org/2020.lrec-1.274/.

[13] Datta, S. y Roberts, K. (2022). Fine-grained spatial information extraction in radiology as two-turn question answering. *International Journal of Medical Informatics*, 158, 104628. https://doi.org/10.1016/j.ijmedinf.2021.104628.

[14] Irvin, J. y cols. (2019). CheXpert: A large chest radiograph dataset with uncertainty labels and expert comparison. *Proceedings of AAAI*, 33, 590–597. https://doi.org/10.1609/aaai.v33i01.3301590.

[15] Peng, Y., Wang, X., Lu, L., Bagheri, M., Summers, R. y Lu, Z. (2018). NegBio: A high-performance tool for negation and uncertainty detection in radiology reports. *AMIA Annual Symposium Proceedings*. https://pmc.ncbi.nlm.nih.gov/articles/PMC5961822/.

[16] Johnson, A. E. W. y cols. (2019). MIMIC-CXR, a de-identified publicly available database of chest radiographs with free-text reports. *Scientific Data*, 6, 317. https://doi.org/10.1038/s41597-019-0322-0.

[17] Jain, S. y cols. (2021). RadGraph: Extracting clinical entities and relations from radiology reports. *NeurIPS Datasets and Benchmarks*. https://arxiv.org/abs/2106.14463.

[18] Delbrouck, J.-B. y cols. (2024). RadGraph-XL: A large-scale expert-annotated dataset for entity and relation extraction from radiology reports. *Findings of ACL*, 12902–12915. https://doi.org/10.18653/v1/2024.findings-acl.765.

[19] Lafferty, J., McCallum, A. y Pereira, F. (2001). Conditional random fields: Probabilistic models for segmenting and labeling sequence data. *ICML*, 282–289. https://www.cs.columbia.edu/~jebara/6772/papers/crf.pdf.

[20] Ratinov, L. y Roth, D. (2009). Design challenges and misconceptions in named entity recognition. *CoNLL*, 147–155. https://aclanthology.org/W09-1119/.

[21] Devlin, J., Chang, M.-W., Lee, K. y Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *NAACL*, 4171–4186. https://doi.org/10.18653/v1/N19-1423.

[22] Lee, J. y cols. (2020). BioBERT: A pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, 36(4), 1234–1240. https://doi.org/10.1093/bioinformatics/btz682.

[23] Alsentzer, E. y cols. (2019). Publicly available clinical BERT embeddings. *Proceedings of the Clinical Natural Language Processing Workshop*, 72–78. https://aclanthology.org/W19-1909/.

[24] Gu, Y. y cols. (2021). Domain-specific language model pretraining for biomedical natural language processing. *ACM Transactions on Computing for Healthcare*, 3(1), 1–23. https://doi.org/10.1145/3458754.

[25] Yan, A., McAuley, J., Lu, X., Du, J., Chang, E. Y., Gentili, A. y Hsu, C.-N. (2022). RadBERT: Adapting transformer-based language models to radiology. *Radiology: Artificial Intelligence*, 4(4), e210258. https://doi.org/10.1148/ryai.210258.

[26] Efron, B. y Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall/CRC.

[27] `python-crfsuite`. (2025). Versión 0.9.12, implementación de CRFsuite para Python. https://pypi.org/project/python-crfsuite/0.9.12/.